

شرح المشروع بالعربية

أثر الدومينو في تأخر الرحلات (L'effet domino des retards) — رحلات مطار أتلانتا، صيف 2022

ملف مراجعة شخصي — سلمى بوحمد — مشروع مادة تصوير البيانات (Visualisation des données)

المشروع في جملة واحدة

حلّلت **54 461** رحلة انطلقت من مطار أتلانتا (أكثر مطار ازدحاماً في العالم) خلال يونيو ويوليو 2022، فكتشفت أن التأخر يكبر مع مرور اليوم، لأن تأخر رحلة ينتقل إلى الرحلة الموالية لنفس الطائرة — وهذا ما نسميه أثر الدومينو. ثم صنعت لوحة قيادة تفاعلية (dashboard) لاستكشاف هذه النتائج.

1. المشكلة التي ندرسها (la problématique)

الانضباط في المواعيد (la ponctualité) هو أهم مؤشر لأي شركة نقل. والتأخر لا يبقى معزولاً: الطائرة (أو الحافلة) منتظرة في مكان آخر، فتأخرها ينتقل إلى رحلاتها التالية. لاحظت نفس الظاهرة في تدريبي بشركة **ALSA أكادير** للنقل الحضري: حافلة متأخرة في رحلتها الأولى تؤخر كل الرحلات التي بعدها.

السؤال الرئيسي: متى ولماذا تتأخر الرحلات المنطلقة من أتلانتا خلال صيف 2022؟

Quand et pourquoi les vols au départ d'Atlanta prennent-ils du retard pendant l'été 2022 ?

1. ما حجم التأخرات؟

2. كيف يتطور التأخر خلال اليوم وخلال الأسبوع؟

3. ما هي الشركات والوجهات الأكثر تأثراً؟

4. هل يُستدرك التأخر أثناء الطيران؟

5. هل ينتقل التأخر من رحلة إلى الرحلة الموالية لنفس الطائرة؟ (أثر الدومينو)

تعريف مهم: نقول إن الرحلة «متأخرة» إذا أقلعت بأكثر من **15 دقيقة** بعد موعدها — وهذا هو التعريف الرسمي للهيئة الأمريكية للإحصاءات BTS (العمود DepDe115).

2. البيانات (le dataset)

العنصر	التفاصيل
المصدر	موقع Kaggle، مجموعة « <i>Flight Status Prediction</i> »
الأصل الرسمي	مكتب إحصاءات النقل الأمريكي (Bureau of Transportation Statistics, BTS) — بيانات حكومية حقيقية
الملف الأصلي	أكثر من 4 ملايين رحلة، من يناير إلى يوليو 2022
نطاق الدراسة (périmètre)	كل الرحلات المنطلقة من أتلانتا في يونيو ويوليو 2022: 54 461 سطرًا × 61 عموداً
أنواع المتغيرات	41 رقمية، 17 فئوية (نصية)، 2 صح/خطأ، 1 تاريخ
الغنى	14 شركة طيران، 147 وجهة، 3 297 طائرة، 61 يوماً

لماذا اخترت هذه البيانات؟

- قارنتُ **7 مجموعات بيانات** في مجال النقل؛ ثلاث منها أقل من 50 عموداً فاستبعدتها.
- بيانات **رسمية وحقيقية**، وغنية (61 عموداً).
- فيها **رقم تسجيل كل طائرة** `Tail_Number`، مما يسمح بتتبع نفس الطائرة خلال اليوم ← الزاوية الأصلية: أثر الدومينو.
- يونيو ويوليو هما **ذروة التأخرات** في السنة ($\approx 26\%$ مقابل $\approx 15\%$ في يناير-فبراير). ويوليو وحده = 533 27 رحلة فقط (أقل من 30 000 المطلوبة)، لذلك أخذتُ الشهرين.

انتبهي: اختيار أتلانتا في يونيو ويوليو ليس **معاينة** (*pas un échantillonnage*)، بل هو **تحديد موضوع الدراسة**. المعاينة جاءت بعد ذلك، على هذه الـ 54 461 رحلة.

العمود	المعنى
FlightDate	تاريخ الرحلة
Airline	شركة الطيران التي تشغل الرحلة
Dest	مطار الوصول (مثلاً MCO = أورلاندو)
CRSDepTime	ساعة الإقلاع المبرمجة (14:35 = 1435)
DepDelay	التأخر عند الإقلاع بالدقائق (سالب = أقلعت مبكراً) — المتغير الرئيسي
DepDel15	1 إذا كان التأخر أكثر من 15 دقيقة، وإلا 0
ArrDelay	التأخر عند الوصول بالدقائق
Tail_Number	رقم تسجيل الطائرة — لتتبع نفس الطائرة
Distance	المسافة بالميل (1 ميل = 1,6 كلم)
Diverted / Cancelled	رحلة ملغاة / رحلة حُوّلت إلى مطار آخر

3. ماذا فعلنا خطوة بخطوة

المرحلة	ماذا فعلنا	لماذا
1. اختيار البيانات	مقارنة 7 مجموعات بيانات، واختيار رحلات الطيران	بيانات رسمية + زاوية أصلية (الطائرة نفسها)
2. الإشكالية	سؤال رئيسي + 5 أسئلة فرعية	كل رسم بياني يجب عن سؤال
3. الاستكشاف والتنظيف	فحص الجودة وتنظيف البيانات (انظري الفقرة 4)	العمل على بيانات موثوقة
4. المعاينة	7 طرق، قياس الأخطاء، ترتيب الطرق (الفقرة 5)	عينة ممثلة لرسم نقاط مقروءة
5-7. التحليلات	تحليل أحادي، ثنائي، ومتعدد المتغيرات (الفقرة 6)	الإجابة عن الأسئلة الفرعية
8. القصة والنتائج	6 نتائج رئيسية (<i>insights</i>) مبنية على الأرقام	رواية قصة واضحة بالبيانات
9-10. لوحة القيادة	7 Streamlit + Plotly، تبيويات، فلاتر تفاعلية، مختبرة	أداة يستعملها أي شخص لاستكشاف النتائج
11. التقرير	تقرير PDF من 6 صفحات	مطلوب في دفتر التحملات
12. العرض الشفهي	12 شريحة لـ 10 دقائق، النص في الملاحظات	التقديم أمام الأستاذ
13. النشر	GitHub عمومي + لوحة القيادة على الإنترنت + 43 اختباراً آلياً	ملف أعمال (<i>portfolio</i>) للتدريب والعمل

4. جودة البيانات وتنظيفها (qualité et nettoyage)

الفحص	النتيجة	القرار
الأسطر المكررة (doublons)	0	لا شيء
القيم الناقصة (valeurs manquantes)	$\approx 2\%$ من الرحلات، في 17 عموداً	أبقيناها دون ملئها: كلها رحلات ملغاة (1 009) أو محوَّلة (123). الرحلة الملغاة ليس لها تأخر، واختراع قيمة لا معنى له.
القيم الشاذة (valeurs aberrantes)	$\approx 12\%$ فوق حد IQR (44,5 دقيقة)، أقصاها 41 ساعة	أبقيناها: إنها تأخرات حقيقية وليست أخطاء. واستعملنا مؤشرات لا تتأثر بها (الوسيط، النسبة المئوية).
الأعمدة الثابتة	10 أعمدة لها قيمة واحدة (مثلاً مدينة الإقلاع = أتلانتا دائماً)	حذفناها: لا تحمل أي معلومة.
أعمدة جديدة	8 أعمدة (الساعة، اليوم، الحالة، الشركة، أثر الدومينو...)	للإجابة عن الأسئلة ولرسوم مقروءة

قاعدة مهمة: الملف الأصلي لا يُعدَّل أبداً؛ ننشئ نسخة مننّظفة في مجلد `data/processed`.

المتوسط والوسيط (moyenne et médiane) — سؤال محتمل جداً

المتوسط = المجموع ÷ العدد، ويتأثر كثيراً بالقيم الكبيرة. الوسيط = القيمة التي في الوسط بعد الترتيب. عندنا: الوسيط = 0 دقيقة، والمتوسط = 16 دقيقة، لأن بعض الرحلات تأخرت ساعات طويلة فرفعت المتوسط. لذلك اخترنا نسبة الرحلات المتأخرة كمؤشر رئيسي.

كيف حسبنا أثر الدومينو؟

- رتبنا الرحلات حسب الطائرة، ثم اليوم، ثم الساعة.
- جمعناها في مجموعات «طائرة واحدة، يوم واحد» (groupby).
- لكل رحلة، أخذنا حالة الرحلة السابقة لنفس الطائرة (shift(1)): هل كانت متأخرة أم لا.

5. المعاينة (l'échantillonnage)

لماذا نحتاج عينة؟ لأن رسم 54 000 نقطة يعطي بقعة غير مقروءة وبطيئة في لوحة القيادة. عينة من 5 000 رحلة (10%) ممثلة (représentative) تعطي نفس الصورة بوضوح. المجتمع الإحصائي (population) = 461 54 رحلة.

الطريقة	المبدأ
عشوائية بسيطة (aléatoire simple)	سحب 5 000 رحلة عشوائياً، لكل رحلة نفس الحظ
منتظمة (systématique)	ترتيب الرحلات حسب التاريخ وأخذ رحلة كل ~11 رحلة
طباقية متناسبة (stratifié proportionnel)	نفس النسبة من كل شركة (دلتا 66 % في العينة كما في الواقع)
طباقية غير متناسبة (stratifié non proportionnel)	نفس العدد من كل شركة (625) ← دلتا تنزل إلى 12,5 %
عنقودية (par grappes)	سحب أيام كاملة عشوائياً (6 أيام)
طباقية زمنية (stratifié temporel)	نفس النسبة من كل يوم من الـ 61 يوماً
بوتستراب (bootstrap)	سحب مع الإرجاع: نفس الرحلة قد تُسحب مرتين (لذلك فيه أسطر مكررة، وهذا طبيعي)

كل الطرق تستعمل «بذرة» random_state = 42 لنحصل على نفس النتيجة في كل مرة (reproductibilité).

كيف نقيس جودة العينة؟

- الخطأ المطلق (erreur absolue) = |قيمة العينة - قيمة المجتمع|. مثال: 26,51 % - 26,25 % = 0,26 نقطة.
- الخطأ النسبي (erreur relative) = الخطأ المطلق ÷ قيمة المجتمع × 100. مثال: 0,26 ÷ 26,25 × 100 ≈ 1 %.
- درجة التمثيلية (score de représentativité) = 100 - متوسط الأخطاء النسبية على 6 مؤشرات. 100 = مطابقة للمجتمع.

الترتيب (متوسط 100 سحبة لكل طريقة)

الرتبة	الطريقة	الدرجة
1	منتظمة	96,7
2	طباقية حسب الشركة	96,1
3	طباقية حسب اليوم ✓ (المختارة)	96,0
4	عشوائية بسيطة	95,8
5	بوتستراب	95,7
6	عنقودية	84,8 — غير مستقرة
7	طباقية غير متناسبة	71,8 — منحازة عمداً

- العنقودية غير مستقرة: نتائجها بين 18 % و 36 % حسب الأيام المسحوبة، لأن التأخر يختلف كثيراً من يوم لآخر (من 10 % إلى 63 %).

- غير المتناسبة منحاذا بطبيعتها؛ لكن إذا أعطينا كل رحلة وزناً (*repondération*)، نسترجع القيمة الصحيحة: 26,1 % مقابل 26,2 % في المجتمع.
- اخترنا الطبقة حسب اليوم: من المجموعة الأولى، أقل تذبذب، وكل الأيام الـ 61 ممثلة.

6. النتائج الرئيسية (*les insights*)

1. التأخر شائع: 26 % من الرحلات تقلع بتأخر أكثر من 15 دقيقة، و 8 % بأكثر من ساعة.
2. التأخر يكبر مع مرور اليوم: 12 % صباحاً مقابل 40 % مساءً — أي 3 أضعاف، وفي كل أيام الأسبوع.
3. أثر الدومينو قابل للقياس: إذا كانت الرحلة السابقة لنفس الطائرة متأخرة، تتأخر الرحلة التالية في 50 % من الحالات، مقابل 24 % فقط إذا كانت في الوقت. والفرق موجود في كل ساعة من اليوم.
4. التأخر يُحسم عند الإقلاع: الارتباط بين تأخر الإقلاع وتأخر الوصول = 0,98. 20 % فقط من الرحلات المتأخرة تصل في الوقت. والمسافة لا علاقة لها بالتأخر (ارتباط 0,01).
5. الشركات ليست متساوية: ساوث ويست (37 %) وفرونتيير (35 %) تتأخران ضعف إنديفور (18 %). وساوث ويست تنهار خاصة في المساء (80 % على الساعة 21).
6. بعض الأيام استثنائية: من 10 % إلى 63 % من الرحلات المتأخرة حسب اليوم (أسوأ يوم: 21 يوليو).

الخلاصة: الرحلات تتأخر خاصة في آخر اليوم، لأن التأخر ينتقل من رحلة إلى أخرى لنفس الطائرة. **الحل المقترح:** حماية الرحلات الأولى في الصباح (هوامش زمنية على الأرض، طائرات احتياطية).

الارتباط ليس سببية (*corrélation ≠ causalité*): رحلتا نفس الطائرة تتشاركان نفس اليوم (الطقس، الازدحام)، لذلك بياناتنا تُظهر ارتباطاً وليس دليلاً قاطعاً على السببية. لكن BTS يعترف رسمياً بهذا السبب للتأخر « *Aircraft Arriving Late* »

7. لوحة القيادة (*le dashboard*)

مصنوعة بـ Streamlit و Plotly، ومنشورة على الإنترنت. فيها فلاتر (الفترة، الشركات، الساعات، أيام الأسبوع)، و 5 مؤشرات رئيسية (*KPI*)، و 7 تبويبات:

1. نظرة عامة: التأخر حسب الساعة، حسب اليوم، يوماً بيوم، وخريطة حرارية يوم × ساعة.
2. أثر الدومينو: 24 % مقابل 50 %، وتطوره حسب الساعة.
3. مقارنة شركتين: ساعة بساعة.
4. الوجهات: رسم فقاعات حسب المسافة ونسبة التأخر.
5. مختبر المعاينة: نختار الطريقة والحجم والبذرة، فنرى الأخطاء والدرجة مباشرة، وترتيب الطرق.
6. جودة البيانات: القيم الناقصة، المكررة، الشاذة، والأعمدة الثابتة.
7. النتائج والحدود.

قواعد التصميم: أزرق = الرحلات عموماً، برتقالي = التأخر وما نريد إبرازه، ألوان مختبرة لمن يعانون من عمى الألوان، عناوين تقول الخلاصة مباشرة، بدون زخرفة غير مفيدة (*data-ink ratio*).

8. حدود الدراسة (*les limites*)

- مطار واحد وشهران فقط في الصيف: لا يمكن تعميم النتائج تلقائياً.
- لا توجد بيانات الطقس ولا الأسباب الرسمية للتأخر في هذا الملف.
- لا نرى رحلات العودة إلى أتلانتا بين إقلاعين لنفس الطائرة.
- دلتا تمثل 66 % من الرحلات.
- كل العلاقات ارتباطات، وليست أدلة على السببية.

9. أسئلة الأستاذ المتوقعة — مع الجواب بالفرنسية

لماذا اخترت هذه البيانات؟

Données officielles et réelles, riches (61 colonnes), dans le transport, et l'immatriculation des avions permet un angle original : l'effet domino.

كيف عالجت القيم الناقصة؟

Elles correspondent toutes aux vols annulés ou déviés. Je ne les ai pas remplies : inventer un retard pour un vol annulé n'aurait pas de sens.

لماذا أبقيت القيم الشاذة؟

Ce sont de vrais retards, pas des erreurs. J'utilise des indicateurs robustes : la médiane et le % de vols en retard.

لماذا هذه الطريقة في المعاينة؟ هل العينة ممثلة؟

J'ai comparé 7 méthodes avec l'erreur absolue, l'erreur relative et un score de représentativité sur 100 tirages. J'ai retenu le stratifié par jour : score 96, 26,5 % de retard contre 26,2 %, et les 61 jours représentés.

لماذا البوتستراب فيه أسطر مكررة؟

Parce qu'il tire avec remise : un même vol peut être tiré deux fois. C'est normal.

ما هو أهم اكتشاف لك؟

L'effet domino : si le vol précédent du même avion était en retard, le suivant l'est deux fois plus souvent (50 % contre 24 %), à chaque heure.

هل يمكن الحديث عن سببية؟

Non. Ce sont des associations : les deux vols partagent la même journée (météo, affluence). L'effet est plausible et reconnu par le BTS, mais mes données seules ne le prouvent pas.

لماذا Streamlit؟

Imposé par le cahier des charges, et adapté : tout en Python, filtres faciles, déploiement gratuit en ligne.

ماذا كنت ستضيف لو كانت لديك بيانات أكثر؟

La météo heure par heure, les causes officielles de retard, une année complète, et les vols arrivant à Atlanta.

كيف اختبرت الكود؟

43 tests automatiques avec pytest : tailles des échantillons, proportions, fichier brut jamais modifié, démarrage du dashboard, filtres.

10. أرقام يجب حفظها

الرقم	المعنى
54 461 × 61	عدد الرحلات × عدد الأعمدة
26 %	نسبة الرحلات المتأخرة (أكثر من 15 دقيقة)
0 / 16 min	الوسيط / المتوسط للتأخر
12 % → 40 %	التأخر صباحاً ← مساءً
24 % → 50 %	أثر الدومينو (الرحلة السابقة في الوقت ← متأخرة)
0,98	الارتباط بين تأخر الإقلاع والوصول
37 % / 18 %	ساوث ويست / إنديفور
10 % → 63 %	أهدأ يوم ← أسوأ يوم (21 يوليو)
66 %	حصة دلتا من الرحلات
7 · 96,0	عدد طرق المعاينة · درجة العينة المختارة

11. قاموس المصطلحات: فرنسي ← عربي

بالفرنسية	بالعربية
<i>Problématique</i>	الإشكالية
<i>Échantillonnage / échantillon</i>	المعاينة / العينة
<i>Population</i>	المجتمع الإحصائي (كل البيانات)
<i>Représentatif</i>	ممثّل (يشبه المجتمع)
<i>Aléatoire / avec remise</i>	عشوائي / مع الإرجاع
<i>Stratifié / strate</i>	طبقي / طبقة
<i>Par grappes</i>	عنقودي
<i>Moyenne / médiane / écart-type</i>	المتوسط / الوسيط / الانحراف المعياري
<i>Valeurs manquantes / doublons</i>	قيم ناقصة / أسطر مكررة
<i>Valeurs aberrantes (outliers)</i>	قيم شاذة
<i>Corrélation ≠ causalité</i>	الارتباط ليس سببية
<i>Analyse univariée / bivariée / multivariée</i>	تحليل أحادي / ثنائي / متعدد المتغيرات
<i>Nuage de points (scatter plot)</i>	رسم النقاط
<i>Carte de chaleur (heatmap)</i>	خريطة حرارية
<i>Tableau de bord (dashboard)</i>	لوحة القيادة
<i>Indicateur clé (KPI)</i>	مؤشر رئيسي
<i>Reproductibilité</i>	إمكانية تكرار النتيجة نفسها
<i>Ponctualité</i>	الانضباط في المواعيد