

L'effet domino des retards

Analyse des vols au départ d'Atlanta pendant l'été 2022 et dashboard interactif

Projet final — Module Visualisation des Données · Salma Bouhmid · Septembre 2026

1. Introduction

La ponctualité est l'indicateur central de tout exploitant de transport. Un retard n'est jamais isolé : le véhicule est attendu ailleurs, et son retard peut se reporter sur ses services suivants — un phénomène observé lors de mon stage chez ALSA Agadir City (transport urbain par bus). Ce projet étudie ce mécanisme sur un cas où les données sont riches et officielles : les vols au départ d'Atlanta, l'aéroport le plus fréquenté du monde.

Problématique : quand et pourquoi les vols au départ d'Atlanta prennent-ils du retard pendant l'été 2022 ?

1. Quelle est l'ampleur des retards ?
2. Comment le retard évolue-t-il au fil de la journée et de la semaine ?
3. Quelles compagnies et quelles destinations sont les plus touchées ?
4. Le retard au départ se rattrape-t-il en vol ?
5. Un retard se transmet-il au vol suivant du même avion (effet domino) ?

Un vol est dit **en retard** s'il part plus de 15 minutes après l'heure prévue (définition officielle du BTS, variable DepDe115).

2. Dataset et méthodologie

Choix du dataset

Sept datasets Kaggle du domaine transport ont été comparés. Trois ont été écartés car ils comptent moins de 50 colonnes (US Accidents : 46, Chicago Traffic Crashes : 48, taxis/vélos : < 25). Parmi les autres (Uber & Lyft Boston, accidents en France et au Royaume-Uni), le dataset **Flight Status Prediction** a été retenu : données officielles du Bureau of Transportation Statistics (BTS), et surtout présence de l'**immatriculation de chaque avion**, qui permet de suivre un même appareil au fil de la journée.

Élément	Valeur
Fichier source	Combined_Flights_2022.parquet — 4 078 318 vols, janvier à juillet 2022
Périmètre d'étude	Tous les départs d'Atlanta (ATL), juin et juillet 2022 : 54 461 vols × 61 colonnes
Types de variables	41 numériques, 17 catégorielles, 2 booléennes, 1 date
Richesse	14 compagnies, 147 destinations, 3 297 avions, 61 jours

Le périmètre est un **choix de sujet**, pas un échantillonnage : juin-juillet est le pic des retards de l'année ($\approx 26\%$ à Atlanta contre $\approx 15\%$ en janvier-février), et juillet seul (27 533 vols) était sous le minimum de 30 000 lignes.

Qualité des données et nettoyage

Contrôle	Constat	Décision
Doublons	0	—
Valeurs manquantes	17 colonnes, $\approx 2\%$ des vols : toutes liées aux 1 009 vols annulés et 123 vols déviés	Gardées, non remplies (un vol annulé n'a pas de retard mesurable)
Valeurs aberrantes	$\approx 12\%$ des vols au-delà de $Q3 + 1,5 \times IQR$ (44,5 min), maximum 41 h	Gardées : ce sont de vrais retards ; indicateurs robustes utilisés (médiane, %)
Colonnes constantes	10 colonnes (ville, État, code de l'aéroport de départ...)	Supprimées : aucune information
Nouvelles colonnes	Heure prévue, jour, statut, compagnie (petites compagnies regroupées), minutes rattrapées	Ajoutées (8 au total)

Indicateur de l'effet domino. Les vols sont triés par avion, par jour puis par heure ; pour chaque départ, `groupby(...).shift(1)` récupère le statut du départ précédent du même avion le même jour (colonne `vol_precedent_en_retard`).

Échantillonnage

Les nuages de points à 54 000 points sont illisibles et lents dans un dashboard : un échantillon représentatif de $\approx 5\,000$ vols (10 %) est nécessaire. Cinq méthodes ont été comparées à la population, sur un tirage puis sur **100 tirages** chacune (`random_state` fixé pour la reproductibilité).

Méthode	% retard	Écart-type (100 tirages)
Population	26,2 %	—
Aléatoire simple	25,8 %	0,55 pt
Systématique (1 vol sur ~ 11)	26,6 %	0,53 pt
Stratifié par compagnie	25,7 %	0,60 pt
Par grappes (6 jours)	26,3 %	3,92 pts
Stratifié par jour (retenu)	26,5 %	0,52 pt




Figure 1 — Sur 100 tirages, les grappes de jours varient de 18 % à 36 %.

Un seul tirage par grappes semblait correct (26,3 %), mais la répétition révèle son instabilité : les retards dépendent fortement du jour (de 10 % à 63 %). L'échantillon **stratifié par jour** est retenu pour les nuages de points ; tous les pourcentages restent calculés sur les 54 461 vols.

3. Analyse

54 461

vols étudiés

26 %

partent avec plus de 15 min de retard

0 / 16 min

retard médian / moyen

× 2,1

risque de retard si le vol précédent était en retard

3.1 Analyse univariée — que se passe-t-il ?




Figure 2 — Distribution très asymétrique : 49 % des vols partent en avance, 8,4 % ont plus d'1 h de retard.




Figure 3 — Delta opère 66 % des vols (Atlanta est sa base principale).

Le retard est **fréquent** (plus d'un vol sur quatre) mais très inégal : la médiane est de 0 minute alors que la moyenne atteint 16 minutes, tirée par une minorité de très gros retards. D'où le choix du **% de vols en retard** comme indicateur principal. La domination de Delta doit être gardée en tête : le taux global d'Atlanta est surtout le sien.

3.2 Analyse bivariable — quand, chez qui, quels facteurs ?




Figure 4 — De ≈ 12 % à 5-6 h à ≈ 40 % à 20 h.




Figure 5 — 50 % de retard si le vol précédent du même avion était en retard, contre 24 %.




Figure 6 — Southwest (37 %) et Frontier (35 %) contre Endeavor (18 %).




Figure 7 — Corrélation départ/arrivée 0,98 : le retard se conserve (échantillon stratifié).

Le retard **s'accumule au fil de la journée** : un vol du soir a environ trois fois plus de risque d'être en retard qu'un vol du matin. La mesure directe de l'effet domino le confirme : quand le départ précédent d'un avion était en retard, son départ suivant l'est **une fois sur deux**. Le retard se joue au sol, avant le décollage : il se retrouve presque entièrement à l'arrivée (seuls 20 % des vols partis en retard arrivent à l'heure, avec ≈ 7 minutes regagnées en vol en médiane) et n'a **aucun lien avec la distance** (corrélation 0,01). Le jour de la

semaine compte moins que l'heure (de 23 % le mardi à 29 % le jeudi). Ces relations sont des **associations**, pas des preuves de causalité.

3.3 Analyse multivariée — quels profils sont à risque ?




Figure 8 — L'écart domino persiste à chaque heure (heures $\geq$ 200 vols).




Figure 9 — Même tendance jusqu'à 16 h, puis Southwest s'effondre ($\approx 80\%$ à 21 h).




Figure 10 — % de vols en retard par jour et par heure : le soir est à risque tous les jours, le mardi reste le plus calme.

En croisant trois variables, l'effet domino **résiste à l'heure de départ** : à heure égale, un vol dont le précédent était en retard a environ deux fois plus de risque de repartir en retard. L'effet domino n'est donc pas qu'un effet « fin de journée ». La comparaison par compagnie montre que le mauvais score de Southwest vient surtout de ses **vols du soir**. Enfin, les destinations les plus touchées sont Orlando (38 %), New York JFK (37 %), Tampa (35 %) : la Floride revient plusieurs fois (hypothèse : orages d'été, non vérifiable sans données météo).

4. Dashboard interactif




Figure 11 — Onglet « Effet domino » du dashboard Streamlit.

Le dashboard (Streamlit + Plotly) est pensé comme un outil d'analyse compréhensible sans explication préalable :

- **Filtres liés** (barre latérale) : période, compagnies, plage horaire, jours de la semaine — tous les indicateurs et graphiques se recalculent.
- **5 KPI** : vols sélectionnés, % en retard (avec l'écart à l'ensemble), durée moyenne d'un retard, % annulés, effet domino (× combien).
- **5 onglets** suivant l'histoire : vue générale (heure, jour, jour par jour, carte jour × heure) · effet domino · comparaison de deux compagnies · destinations · insights et limites.
- **Interactions** : infobulles détaillées, zoom, sélection des compagnies à comparer, seuil minimal de vols par destination.
- **Garde-fous** : les pourcentages calculés sur trop peu de vols sont masqués et signalés, pour ne jamais afficher un résultat trompeur.

Identité visuelle commune au notebook, aux slides et au dashboard : bleu pour les vols en général, orange pour le retard et ce qui est mis en avant ; palette vérifiée pour les personnes daltoniennes ; titres qui énoncent la conclusion du graphique.

5. Insights

- 1. Le retard est fréquent.** 26 % des vols partent avec plus de 15 min de retard ; 8 % avec plus d'une heure.
- 2. Il grandit au fil de la journée.** $\approx 12\%$ à 6 h contre $\approx 40\%$ à 20 h, tous les jours de la semaine.
- 3. L'effet domino est mesurable.** 50 % de retard si le vol précédent du même avion était en retard, contre 24 %, à chaque heure.
- 4. Le retard se joue au départ.** Corrélation départ/arrivée 0,98 ; la distance ne joue aucun rôle.
- 5. Les compagnies ne se valent pas.** Southwest et Frontier sont deux fois plus souvent en retard qu'Endeavor.
- 6. Certains jours font exploser les retards.** De 10 % à 63 % de vols en retard selon le jour.

6. Limites

- **Représentativité** : un seul aéroport et deux mois d'été ; les résultats ne se généralisent pas automatiquement à l'hiver ni à d'autres aéroports.
- **Variables absentes** : pas de météo, pas de causes officielles de retard dans ce fichier (elles existent dans les fichiers bruts mensuels), pas de nombre de passagers.
- **Effet domino partiel** : seuls les départs d'Atlanta sont observés ; le vol retour vers Atlanta entre deux départs n'est pas dans le périmètre.
- **Déséquilibre** : Delta représente 66 % des vols ; les petites compagnies, regroupées en « Autres », ont des pourcentages moins fiables.
- **Causalité** : toutes les relations sont des associations. Deux vols d'un même avion partagent la même journée (météo, affluence) ; l'effet domino est plausible et reconnu par le BTS (« Aircraft Arriving Late »), mais ces données seules ne le prouvent pas.

7. Conclusion

À Atlanta pendant l'été 2022, les vols prennent surtout du retard **en fin de journée**, parce que les retards **se transmettent d'un vol à l'autre du même avion**. Ce mécanisme touche toutes les compagnies, mais certaines y sont nettement plus exposées, et quelques jours exceptionnels aggravent fortement la situation. Le levier le plus efficace serait donc de **protéger les premières rotations de la journée** (marges au sol, avions de réserve). Avec plus de données, on ajouterait la météo horaire, les causes officielles de retard et une année complète pour comparer les saisons. Le même raisonnement s'applique directement à la ponctualité d'un réseau de bus.

Code, notebook et dashboard : dossier du projet (notebooks/analysis.ipynb, src/, dashboard/app.py). Données : BTS via Kaggle « Flight Status Prediction » (robikscube).